MACHINE LEARNING CANVAS

Designed for: Equipo 01 Designed by: MiBici Date: 12/10/2026 Iteration: 1 .

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

Enfoque híbrido que abarca regresión supervisada (P1), clasificación supervisada (P2) y clustering no supervisado (P3).

Cicloestaciones individuales del sistema MiBici del Área Metropolitana de Guadalajara (AMG).

Los posibles resultados predecir:

P1: Conteo absoluto de viajes iniciados por estación en el siguiente bloque horario.

P2: Variable binaria (1 si existe riesgo crítico de desabastecimiento de bicicletas o saturación de anclajes; 0 en operación normal).

P3: Identificador de clúster o categoría de comportamiento operativo de la estación.

Se observan los resultados al concluir cada hora u horizonte temporal operativo seleccionado para la evaluación.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

Planificación operativa: Asignación dinámica de rutas y prioridades para la flota de vehículos de rebalanceo de flotas.

Mitigación preventiva: Reubicación proactiva de unidades hacia estaciones clasificadas con riesgo crítico de desabastecimiento.

Expansión de red: Identificación de la vocación urbana de cada zona para justificar la apertura de nuevas cicloestaciones o incentivos tarifarios.

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiario final: Operadores logísticos de rebalanceo y directivos de planeación urbana del sistema MiBici.

Problema que resuelve: Anticipar picos de demanda, prevenir el desabastecimiento de bicicletas en estaciones críticas y evitar la saturación de anclajes en horas pico, reduciendo en un 15% las quejas por estaciones vacías y optimizando las rutas de las camionetas de redistribución.

Integración e Interfaz: Integración mediante tableros operativos internos (MLflow / Streamlit) y reportes o alertas automatizadas que sugieren flotas de traslado preventivas antes de cada jornada.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Ingesta inicial y continua: Automatizada mediante el script ejecutable dataset.py, que descarga los archivos mensuales, normaliza el esquema de datos y los consolida en formato optimizado Apache Parquet.

Control y Costos: Versionado riguroso mediante un manifiesto con hashes SHA-256 (manifest.json) almacenado en el repositorio de Git, garantizando la reproducibilidad sin incurrir en costos de almacenamiento en la nube.

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Portal de Datos Abiertos de MiBici (archivos CSV mensuales de viajes históricos desde 2023).

Archivos mensuales de nomenclatura oficial de estaciones (nomenclatura_estaciones.parquet), que contienen coordenadas geográficas (latitud, longitud) y capacidad máxima de anclaje (dpcapacity).

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Métricas de Éxito: Minimización de kilómetros recorridos y costos operativos por las camionetas de rebalanceo, y maximización de viajes completados con éxito por los ciudadanos.

Criterios de Despliegue: Validación rigurosa superando las métricas de los modelos baseline en los conjuntos de prueba independientes y verificación de ausencia de sesgo en las particiones temporales.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Modalidad y Frecuencia: Ejecución en modo lote (batch inference) de forma diaria o semanal mediante scripts dedicados (predict.py).

Recursos y Tiempos: Procesamiento rápido en servidores locales o estaciones de trabajo CPU estándar utilizando Pandas y matrices vectorizadas en NumPy, completando el ciclo de inferencia en segundos.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

P1 (Regresión): Predicción de volumen absoluto de viajes por estación (Baseline: DummyRegressor vs. Candidato: RandomForestRegressor / LightGBM).

P2 (Clasificación): Predicción de riesgo crítico de desabastecimiento/saturación (Baseline: DummyClassifier vs. Candidato: LogisticRegression / GradientBoosting).

P3 (Clustering): Agrupamiento no supervisado de estaciones por perfiles horarios (Baseline: K-Means aleatorio vs. Candidato: K-Means++ con múltiples arranques).

Trazabilidad: Todos los modelos registran parámetros, hiperparámetros, métricas (test_rmse, test_roc_auc, test_silhouette_score) y artefactos en MLflow Tracking (mibici-equipo01).

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Variables Temporales: Hora del día, día de la semana (day_of_week), indicador de fin de semana (is_weekend).

Variables Históricas / Lags: Desplazamientos temporales (lags de 1 hora, 24 horas y 7 días) y flujos netos acumulados (entradas menos salidas de bicicletas por estación).

Atributos Geoespaciales y Perfiles: Coordenadas espaciales normalizadas y matrices de perfiles horarios de uso de las estaciones (para P3).

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
How often should they be reviewed?

Seguimiento de KPIs: Revisión periódica del desempeño de los modelos a través de las métricas principales (RMSE, ROC-AUC, Silhouette Score) registradas en MLflow.

Detección de Deriva: Auditorías continuas de los perfiles horarios para detectar cambios estructurales en la movilidad urbana (data drift).

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO

What your canvas is for

A filled canvas does 4 jobs, and each one needs certain boxes filled in with care.

- **Deciding what's worth building.** Put each idea on its own canvas and you can compare the ideas on the same terms: what each could gain in a year, and whether the outcomes a model would learn from were ever recorded. That takes dollar amounts in the Impact Simulation box, and a named person in the Value Proposition box who acts on each prediction.
- **Agreeing on what gets built.** Some of the choices that set a system's value look technical, but they're business decisions. What counts as a lost customer: 60 days without buying, or 90? How far ahead do you predict? How many flagged cases can your team act on? On the canvas, business, data and engineering make these choices together, instead of leaving them to whoever writes the code.
- **Knowing when the model is good enough.** The Impact Simulation box sets the performance the model has to reach to pay off. Test the model on enough of the cases you're predicting: 35,000 machine-hours of data can hold just 3 failures, too few to measure anything.
- **Learning after launch.** If acting on a prediction changes the outcome, keep a small share of flagged cases untouched and record that share in the Decisions box, so you can see what your action changed.

Whatever you can't answer is the work left before anyone writes code.

"The Canvas allowed us to structure and focus our delivery sprints. The ML system went live in June 2020 and still is."
— Christian Schiller, Senior IT & Enterprise Architect, Deutsche Telekom

Book a project review

Louis Dorard created the canvas in 2015. Book a free 30-minute call, then send him your canvas draft, or a few lines about the project if you haven't started one. He prepares the call from what you send, and you'll leave knowing where the project is likely to break, and what to check before anyone builds it.

Book a 30-minute call →

Reference the Machine Learning Canvas

If you need to reference the Canvas formally (e.g. in documentation or publications), you may use:

```
@misc{mlc,
  title  = "Machine Learning Canvas",
  author = "Louis Dorard (OWNML)",
  url    = "https://www.ownml.co/",
  year   = "2015"
}
```

"MLC played an essential role in a positive project outcome. It is now being used throughout the organization."
— Daitan, now part of Coforge, a global IT services firm