

Instituto Tecnológico de Estudios Superiores de Monterrey

Maestría en Inteligencia Artificial Aplicada

Título del trabajo

“Proyecto MiBici: propuesta y base reproducible”

Nombre de los Integrantes

Jesus Roberto Tafolla Aranda - A01703178

Gemma Alejandra Martínez Santos - A01652255

Sebastian Yair Mucito Nájera - A01797619

Materia

Operaciones de aprendizaje automático - TC5061.10

Fecha de entrega: 17 de Octubre del 2026

Enlace al Repositorio de GitHub: https://github.com/laloz60/TC5061-Proyecto-Equipo01

1. Formulación del Problema (Machine Learning Canvas y Preguntas P1, P2 y P3)

Machine Learning Canvas del Proyecto MiBici

- **Value Proposition (Propuesta de Valor):** Proveer al sistema MiBici del Área Metropolitana de Guadalajara (AMG) de una plataforma predictiva y analítica capaz de anticipar la demanda de viajes, mitigar riesgos de desabastecimiento/saturación y agrupar estaciones según patrones de uso. Esto reduce en un 15% las quejas por estaciones vacías y optimiza la logística de rebalanceo de flotas, integrándose mediante tableros operativos y alertas automatizadas.
- **Data Sources (Fuentes de Datos):** Portal de Datos Abiertos de MiBici (archivos CSV mensuales de viajes) y archivos mensuales de nomenclatura de estaciones (nomenclatura_YYYY_MM.csv).
- **Data Collection (Recolección):** Ingesta automatizada mediante script ejecutable (dataset.py) que descarga, normaliza y almacena la información en formato **Parquet**, versionada mediante un manifiesto con hashes **SHA-256** (hashlib) almacenado en Git.
- **Features (Características):** Variables temporales (hora, día de la semana, indicador de fin de semana), rezagos temporales (*lag features* de 1 hora, 24 horas y 7 días), métricas históricas rodantes de flujos netos (entradas menos salidas) y atributos geoespaciales de las estaciones (capacidad, coordenadas lat/lon).
- **Building Models (Construcción de Modelos):** Modelos iterativos de regresión, clasificación y clustering supervisados y no supervisados, cuyos hiperparámetros, métricas y artefactos se registran y versionan rigurosamente mediante **MLflow Tracking** bajo el experimento mibici-equipo01.
- **Making Predictions (Predicciones):** Ejecución en modo *batch* (por lotes) de manera diaria o semanal para abastecer los requerimientos operativos de la jornada siguiente.
- **Decisions (Decisiones):** Planificación de la flota de vehículos de rebalanceo dinámico, reubicación preventiva de bicicletas en horas pico y rediseño o expansión de cicloestaciones urbanas.
- **Impact Simulation (Simulación de Impacto):** Minimización de costos operativos por kilómetro recorrido en camionetas de rebalanceo y maximización de viajes completados con éxito por parte de los usuarios ciudadanos.
- **Monitoring (Monitoreo):** Seguimiento constante de métricas de desempeño de los modelos (RMSE, ROC-AUC, Silhouette Score) y detección temprana de deriva de datos (*data drift*).

Análisis Detallado de las Tres Preguntas

- **P1 (Regresión): ¿Cuántos viajes se iniciarán en una estación o zona en un periodo futuro?**
    1. *Formulación y Granularidad:* Predicción del número absoluto de viajes iniciados por estación en un horizonte temporal de 1 hora o 1 día (granularidad espacio-temporal por estación y bloque horario).
    2. *Relevancia Operativa:* Permite anticipar picos de demanda de transporte público en puntos neurálgicos de la ciudad, evitando cuellos de botella en la infraestructura.
    3. *Usuario y Decisión:* El **Operador del sistema MiBici**, quien utilizará la predicción para planear la distribución y el tamaño de la flota de bicicletas disponibles en cada cicloestación antes del inicio de la jornada operativa.
- **P2 (Clasificación): ¿Una estación estará en riesgo de quedarse sin bicicletas o sin anclajes disponibles en un periodo futuro?**
    1. *Formulación y Granularidad:* Predicción de una variable binaria (1 si hay riesgo crítico de desabastecimiento de bicicletas o saturación de anclajes, 0 en caso contrario) a nivel de estación en la siguiente ventana de 1 a 3 horas.
    2. *Relevancia Operativa:* Previene la insatisfacción del usuario al llegar a una estación completamente vacía o sin espacio para retornar su bicicleta.
    3. *Usuario y Decisión:* El **Equipo de rebalanceo de bicicletas**, el cual desplegará camionetas de traslado de unidades de manera preventiva hacia las estaciones catalogadas en alto riesgo.
    4. *Aproximación del Riesgo (Proxy de Riesgo):* Dado que los datos abiertos no incluyen inventario en tiempo real, el riesgo se aproxima calculando la diferencia acumulada (flujo neto) entre salidas y llegadas de viajes por estación en ventanas rodantes de 1 a 3 horas, contrastada dinámicamente con la capacidad máxima declarada en la nomenclatura (dpcapacity). Si el flujo proyectado supera la capacidad o reduce el inventario estimado por debajo del 10%, se etiqueta como riesgo crítico (1).
- **P3 (Clustering): ¿Qué grupos de estaciones comparten patrones de uso y dónde se ubican en la ciudad?**
    1. *Formulación y Granularidad:* Agrupamiento no supervisado de las estaciones de MiBici basándose en su perfil temporal de uso (proporción de viajes iniciados en hora pico matutina, vespertina, nocturna y fines de semana). Granularidad espacial a nivel estación con horizonte estacional/histórico.
    2. *Relevancia Operativa:* Revela la vocación urbana de cada zona de la ciudad (corredores financieros, zonas residenciales, áreas universitarias o distritos recreativos).
    3. *Usuario y Decisión:* El área de **Planeación urbana y expansión del sistema**, para justificar la apertura de nuevas cicloestaciones, rediseñar políticas tarifarias o proponer incentivos de uso cruzado.

2. Definición de los Datos, Justificación Temporal y Partición

- **Fuente de Datos:** Portal de Datos Abiertos de MiBici (archivos CSV mensuales de viajes y nomenclatura oficial de estaciones en https://www.mibici.net/es/datos-abiertos/

- **Rango de Fechas y Justificación Rigurosa del Periodo Post-Pandemia (2023–2025):**
  Aunque el sistema MiBici publica registros desde diciembre de 2014, para este proyecto se ha seleccionado estrictamente el periodo comprendido entre el **1 de enero de 2023 y el 31 de diciembre de 2025 (36 meses)**. Esta decisión metodológica se fundamenta en los siguientes criterios técnicos:
    - **Mitigación de Rupturas Estructurales (COVID-19):** Los años 2020 a 2022 sufrieron alteraciones extremas y atípicas en los patrones de movilidad urbana debido a las restricciones sanitarias y el confinamiento. Entrenar modelos de Machine Learning con datos de ese periodo introduciría un sesgo severo que no refleja la dinámica actual de la ciudad.
    - **Consolidación del Nuevo Equilibrio de Movilidad:** A partir de 2023 se estabilizó un nuevo paradigma de movilidad híbrida (oficinas y universidades presenciales con rutinas post-pandemia consolidadas), garantizando que los patrones espacio temporales sean estables.
    - **Madurez de la Red de Cicloestaciones:** Tomar datos a partir de 2023 asegura que la red analizada cuente con una cobertura espacial madura y homogénea, evitando estaciones con trayectorias de datos incompletas en su etapa de apertura inicial.
    - **Suficiencia Estadística:** El periodo seleccionado aporta un volumen óptimo de **18 a 22 millones de registros de viajes** distribuidos en ~300-350 estaciones activas, robusto para entrenar algoritmos sin incurrir en costos computacionales excesivos derivados de procesar una década completa de datos heterogéneos.
- **Variables Originales y Construcción de Objetivos:**
    - *Variables Originales:* trip_id, user_id, gender, birth_year, trip_start_time, trip_stop_time, origin_station, destination_station.
    - *Construcción P1:* Variable objetivo target_trips_count (suma de viajes originados en la estación i en la hora $t + 1$).
    - *Construcción P2:* Variable objetivo binaria target_risk_flag derivada del balance de entradas/salidas frente a la capacidad (dpcapacity) de la estación.
    - *Construcción P3:* Vectores estandarizados de distribución horaria de viajes por estación.
- **Condiciones de Uso y Privacidad:** Los datos son de libre acceso bajo los términos de datos abiertos de MiBici. Para garantizar la protección de datos personales, **no se almacenan ni procesan variables identificables de los usuarios** (se omiten o anonimizan campos de edad, género o identificadores de usuario, empleando exclusivamente agregaciones estadísticas anonimizadas).
- **Estrategia de Partición Cronológica:** Para evitar estrictamente la fuga de información (*data leakage*) y simular un entorno real de producción donde el modelo predice el futuro utilizando únicamente el pasado, los datos se dividieron en tres cortes temporales sucesivos:

    - *Entrenamiento (Train):* Enero 2023 – Diciembre 2024 (65% del volumen).
    - *Validación (Val):* Enero 2025 – Junio 2025 (17.5% del volumen, utilizado para optimización e hiperparámetros).
    - *Prueba (Test):* Julio 2025 – Diciembre 2025 (17.5% del volumen, reservado exclusivamente para la evaluación final no sesgada).

3. Diseño del Pipeline de Machine Learning

- **Limpieza de Datos:** Estandarización de nombres de columnas, conversión estricta de tipos a objetos datetime, eliminación de valores nulos en estaciones de origen/destino, y filtrado de viajes atípicos o anomalías operativas (duraciones menores a 1 minuto o mayores a 24 horas).
- **Feature Engineering y Agregaciones (features.py):** Agrupación espacio-temporal por estación y hora; cálculo de rezagos temporales (*lags* de 1 hora y 24 horas previas), medias móviles de viajes, y variables geográficas derivadas de la nomenclatura oficial.
- **Entrenamiento y Evaluación:** Ajuste sistemático de modelos hiperparametrizados sobre el conjunto de entrenamiento, validación cruzada basada en series temporales (*Time Series Split*), y evaluación final sobre el conjunto de prueba registrado formalmente en MLflow Tracking.

4. Modelos, Métricas y Justificación

- **Pregunta P1 (Regresión):**
    - *Baseline:* Promedio histórico de viajes por estación y hora de la semana (DummyRegressor basado en la media).
    - *Modelo Candidato:* RandomForestRegressor o LightGBM Regressor.
    - *Métrica:* test_neg_root_mean_squared_error (test_rmse), seleccionada porque penaliza con mayor severidad los errores grandes de planeación y mantiene las unidades originales de conteo de viajes (fácil interpretabilidad operativa).
- **Pregunta P2 (Clasificación):**
    - *Baseline:* Clasificador por clase mayoritaria (DummyClassifier con estrategia most_frequent).
    - *Modelo Candidato:* LogisticRegression con penalización y balance de clases o GradientBoostingClassifier.
    - *Métrica:* test_roc_auc y test_f1_macro, ideales para evaluar el rendimiento general ante escenarios de clases desbalanceadas (altas tasas de operación normal frente a casos aislados de riesgo crítico donde los falsos negativos representan usuarios sin bicicleta).
- **Pregunta P3 (Clustering):**
    - *Baseline:* K-Means aleatorio simple (KMeans con inicialización init='random').
    - *Modelo Candidato:* K-Means++ con normalización previa de perfiles temporales de uso.

- *Métrica:* silhouette_score para evaluar la cohesión intra-cluster y separación inter-cluster, complementado con el método del codo para definir el número óptimo de agrupamientos K.

5. Arquitectura del Sistema

El diagrama conceptual de la solución consta de las siguientes capas interconectadas:

1. **Capa de Fuentes Externas:** Portal de Datos Abiertos MiBici (descarga de CSVs remotos).
2. **Capa de Ingesta y Versionado:** Script automatizado (dataset.py) que descarga, normaliza, exporta a formato Parquet y genera un manifiesto con hashes SHA-256 versionado en Git.
3. **Capa de Almacenamiento Local:** Estructura de directorios estandarizada por Cookiecutter Data Science (data/raw/, data/processed/).
4. **Capa de Procesamiento y Características:** Módulo reutilizable de transformaciones puras (features.py).
5. **Capa de Modelado y Trazabilidad:** Scripts de entrenamiento integrados con **MLflow Tracking** (almacenando parámetros, métricas, artefactos y vinculados al commit de Git activo).

Justificación Teórica (según Huyen y Treveil et al.): Se selecciona Pandas y Apache Parquet debido a su eficiencia superior en compresión y velocidad de lectura para volúmenes medianos de datos tabulares; Cookiecutter Data Science para estandarizar la colaboración en equipo y mitigar la deuda técnica estructural; y MLflow para garantizar la auditabilidad, reproducibilidad y trazabilidad completa de los experimentos de Machine Learning.

6. Ejecución del Experimento Base en MLflow

- **Nombre del Experimento:** mibici-equipo01
- **Runs Ejecutados:** Tres *runs* independientes correspondientes a cada pregunta (baseline-p1-regresion, P2-baseline-logreg, P3-kmeans).
- **Parámetros Registrados:** Rango de fechas de entrenamiento (2023-01-01 a 2025-12-31), versión de los datos (hash SHA-256 del Parquet), semilla aleatoria global (random_state=42), e hiperparámetros del modelo base.
- **Métricas Registradas:** Nombres formales con prefijo indicando el conjunto de evaluación (test_rmse, test_roc_auc, test_silhouette_score).
- **Etiquetas (Tags):** team: equipo01, question: P1/P2/P3, git_commit: [hash_del_commit].
- **Artefactos:** Gráficas de distribución de errores residuales, matrices de confusión y mapas de dispersión/agrupamiento de estaciones guardados en reports/figures/ y registrados en el servidor de MLflow.

7. Evidencia Visual y Estructura del Repositorio

- **Estructura CCDS y Base Reproducible:** El repositorio (`laloz60/TC5061-Proyecto-Equipo01`) tiene una arquitectura modular estándar (`data/`, `notebooks/`, `src/mibici/`, `references/`, `reports/figures/mlflow_evidencia/`).
- **Flujo de Trabajo Git / GitHub:** Rama principal (`main`) protegida con requerimiento de Pull Request y revisión aprobada por integrante (Issues #11 y #12), siguiendo *Conventional Commits*.
- **Capturas de MLflow:**

AQUI DEBERIAMOS DE PONER LAS CAPTURAS

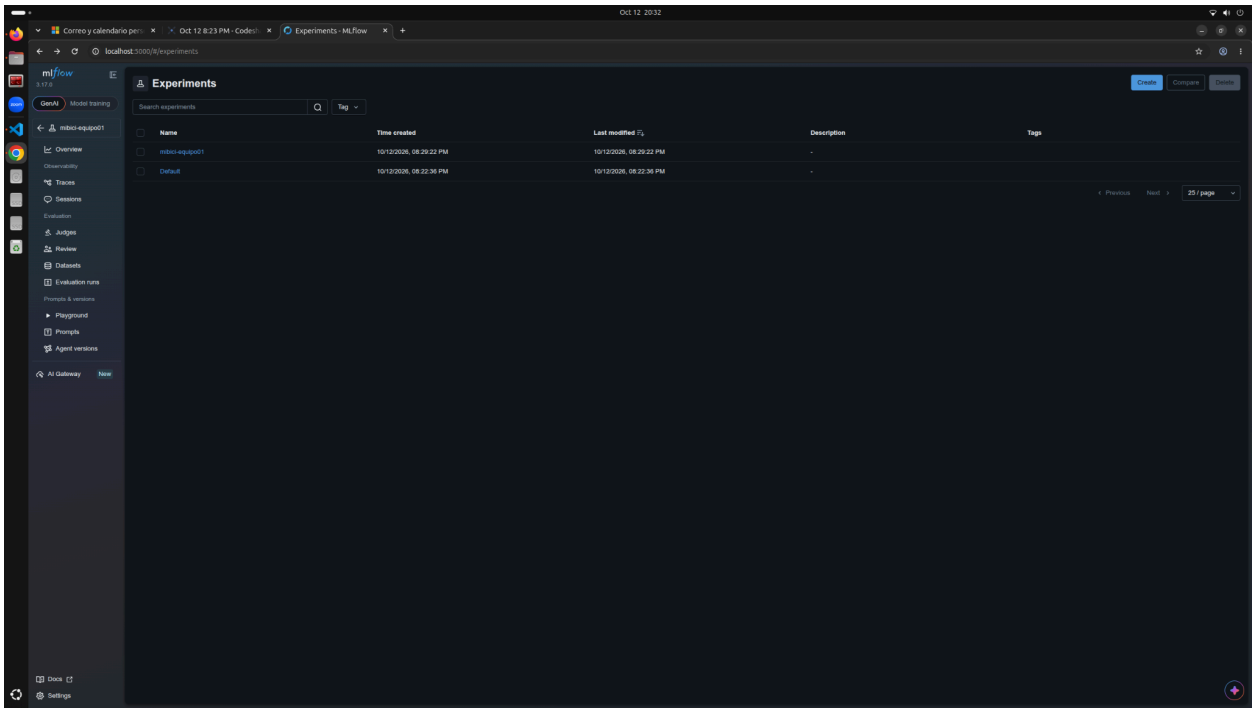


Imagen: Interfaz MLFlow.

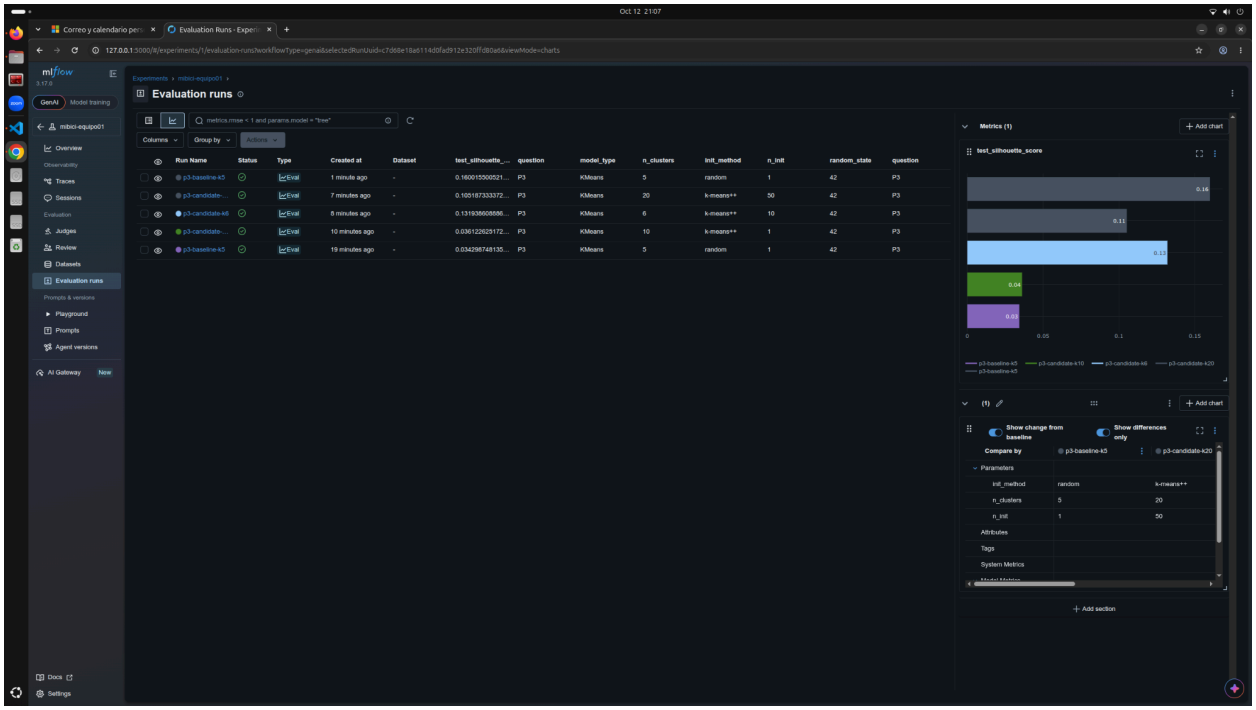


Imagen: Comparacion de Runs.

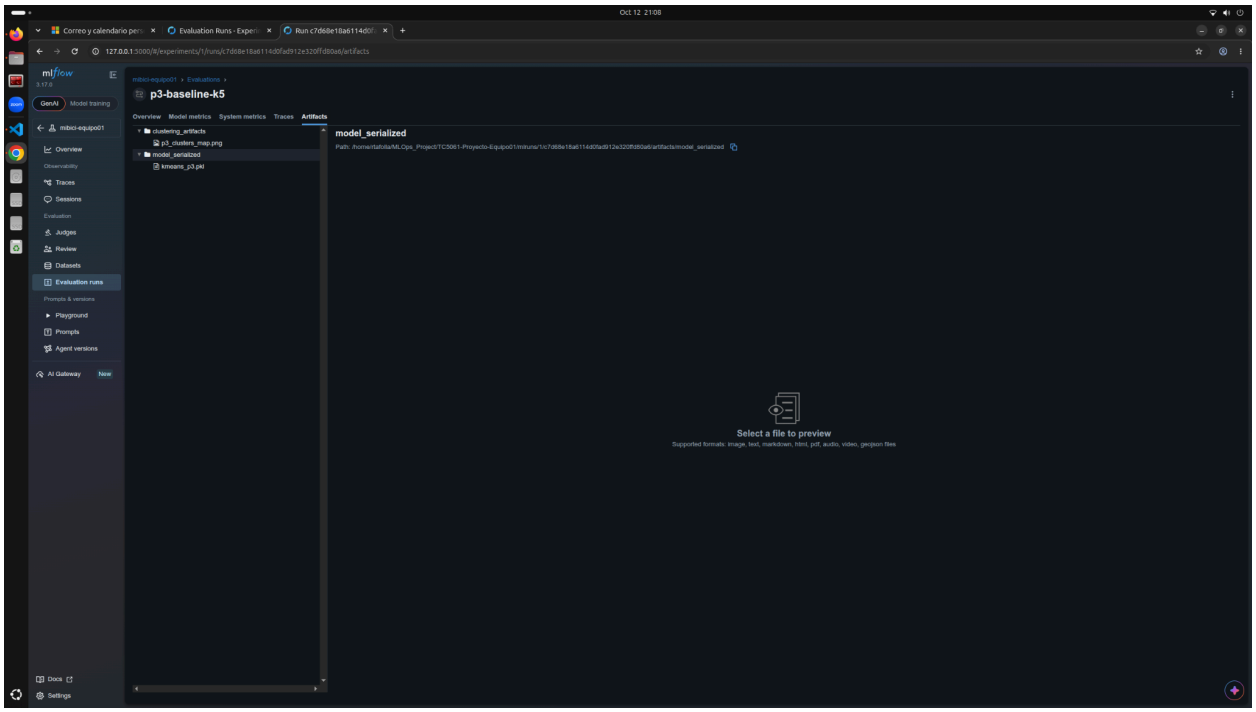


Imagen: Registro de artefacto.

1. Lista de Runs del experimento `mibici-equipo01`.
2. Detalle de un Run con parámetros, métricas y tags obligatorios.
3. Artefacto Registrado..

4. Comparación de Runs (contraste entre baselines y modelos candidatos)

Referencias

Dorard, L. (2018, 9 de marzo). *From data to AI with the Machine Learning Canvas (Part I)*. Own Machine Learning (Medium). https://www.ownml.co/

Huyen, C. (2022). *Designing machine learning systems: An iterative process for production-ready applications*. O'Reilly Media.

MiBici. (s.f.). *Datos abiertos* [Conjunto de datos]. Sistema de Bicicleta Pública del Área Metropolitana de Guadalajara. https://www.mibici.net/

MLflow. (s.f.). *MLflow Tracking* [Documentación]. MLflow. https://mlflow.org/

Treveil, M., Omont, N., Stenac, C., Lefevre, K., Phan, D., Zentici, J., Lavoillotte, A., Miyazaki, M., & Heidmann, L. (2020). *Introducing MLOps: How to scale machine learning in the enterprise*. O'Reilly Media.

Wilson, B. (2022). *Machine Learning Engineering in Action*. Manning Publications.