Code

feat(data): validar datos con DeepChecks y quitar viajes duplicados de las features #117

laloz60/TC5061-Proyecto-Equipo01:feat/validacion-deepchecks

Merged laloz60 merged 1 commit into `main` from `feat/validacion-deepchecks` 7 minutes ago

Conversation 0 Commits 1 Checks 0 Files changed 11 +661 -9

Reviewers

laloz60

JesusTafolla

GemmaMartinez

Assignees

smuciton

Labels

None yet

Projects

None yet

Milestone

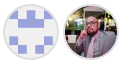
No milestone

Development

Successfully merging this pull request may close these issues.

None yet

2 participants



smuciton commented 15 hours ago

Collaborator

Cierra #98

Qué hace

- Agrega `mibici/data_validation.py`, con chequeos de tipos, faltantes, duplicados y drift entre train y test.
- Agrega `make validation_env` y `make validate`, e incluye la validación en `check-all`.
- Guarda la salida en `reports/data_validation/resumen.json` y documenta hallazgos y acciones en `reports/validacion_datos.md`.
- Corrige el README: la sección llamada "DeepChecks" en realidad corría `pytest tests/test_modeling.py`.

Hallazgos

Chequeo	Resultado	Acción
Tipos	Sin diferencias con el esquema	La validación falla si cambia
Faltantes	`genero` 0.68%; `anio_nacimiento` 0.05%	Se conservan: los modelos no los usan
Duplicados	758 filas exactas en 2026-09; 307 viajes iguales con otro `viaje_id`	Se quitan las 758 en `features.py`; las 307 se conservan

Chequeo	Resultado	Acción
Drift	Ninguna columna alcanza 0.2; el máximo es `mes`, con 0.181	Sin cambios; `mes` queda en observación

Decisiones para revisar

1. **Entorno aparte:** `deepchecks` 0.19.1 no funciona con scikit-learn 1.9 ni NumPy 2. Lo quité de `requirements.txt` (**@JesusTafolla**, tú lo habías agregado) y ahora vive en `requirements-validation.txt`.
2. **`make test`:** la prueba lanza la validación con el Python del entorno aparte, sobre datos inventados. Si ese entorno no existe, se salta.
3. **Duplicados:** se corrigen en las features, no en el Parquet, para no cambiar el manifiesto del equipo. `proxy_riesgo.py` y P3 leen el Parquet directamente y siguen incluyendo esas 758 filas.
4. **Features:** hay que regenerarlas con `python -m mibici.features` para aplicar la corrección.
5. **`setuptools`:** `pip-audit` lo reporta, pero no se puede subir porque `deepchecks` necesita `pkg_resources`. El riesgo queda documentado en el reporte.

Evidencia

- `pytest`: 34 passed. Para que pase la prueba de conteo de viajes, regeneré mi manifiesto local con mis datos, y ese archivo no va en este PR.
- `ruff check mibici tests`: solo los 3 errores preexistentes de `train.py`.
- Validación completa sobre 15,376,153 viajes: terminó correctamente.

Pendientes para el revisor

- **`make validate`:** no lo pude correr porque no tengo `make` en Windows. Probé directamente sus comandos de validación; ¿alguien con `make` lo puede confirmar?
- **`DeepChecks.png`:** muestra las pruebas de modelado. Cambié su texto en el README, pero no renombré el archivo porque es evidencia de **@GemmaMartinez**.





smuciton requested review from **GemmaMartinez**, **JesusTafolla** and **laloz60** 15 hours ago

smuciton self-assigned this 15 hours ago

GemmaMartinez mentioned this pull request 12 hours ago

[docs] Evidencia de PRs y revisiones por integrante #108

5 tasks

Open



laloz60 approved these changes 40 minutes ago

View reviewed changes

laloz60 left a comment

Owner

Se ve bien. La validación con DeepChecks en su propio entorno evita el problema de versiones, y quitar los 758 viajes duplicados por `viaje_id` es un buen hallazgo. Aprobado 👍

a01797668-stack mentioned this pull request 29 minutes ago

[git] Trabajo colaborativo: rama y PR por integrante con revisión cruzada #109

7 tasks

Open

laloz60 merged commit **6248328** into `main` 7 minutes ago

Revert

Pull request successfully merged and closed

You're all set — the `feat/validacion-deepchecks` branch can be safely deleted.

Delete branch