

Instituto Tecnológico de Estudios Superiores de Monterrey

Maestría en Inteligencia Artificial Aplicada

Título del trabajo

“Proyecto MiBici: propuesta y base reproducible”

Nombre de los Integrantes

Jesus Roberto Tafolla Aranda - A01703178

Gemma Alejandra Martínez Santos - A01652255

Sebastian Yair Mucito Nájera - A01797619

Gerardo Carreño García - A01797668

Materia

Operaciones de aprendizaje automático - TC5061.10

Fecha de entrega: 17 de Octubre del 2026

Enlace al Repositorio de GitHub: https://github.com/laloz60/TC5061-Proyecto-Equipo01

1. Formulación del Problema (Machine Learning Canvas y Preguntas P1, P2 y P3)

Machine Learning Canvas del Proyecto MiBici

- **Value Proposition (Propuesta de Valor):** Proveer al sistema MiBici del Área Metropolitana de Guadalajara (AMG) de una plataforma predictiva y analítica capaz de anticipar la demanda de viajes, mitigar riesgos de desabastecimiento/saturación y agrupar estaciones según patrones de uso. Esto busca reducir las quejas por estaciones vacías y optimiza la logística de rebalanceo de flotas, integrándose mediante tableros operativos y alertas automatizadas.
- **Data Sources (Fuentes de Datos):** Portal de Datos Abiertos de MiBici (archivos CSV mensuales de viajes) y el archivo de nomenclatura vigente de estaciones (nomenclatura_2026_09.csv).
- **Data Collection (Recolección):** Ingesta automatizada mediante script ejecutable (dataset.py) que descarga, normaliza y almacena la información en formato **Parquet**, versionada mediante un manifiesto con hashes **SHA-256** (hashlib) almacenado en Git.
- **Features (Características):** Variables temporales (hora, día de la semana, indicador de fin de semana), rezagos temporales (*lag features* de 1 hora, 24 horas y 7 días), métricas históricas rodantes de flujos netos (entradas menos salidas) y atributos geoespaciales de las estaciones (capacidad, coordenadas lat/lon).
- **Building Models (Construcción de Modelos):** Modelos iterativos de regresión, clasificación y clustering supervisados y no supervisados, cuyos hiperparámetros, métricas y artefactos se registran y versionan rigurosamente mediante **MLflow Tracking** bajo el experimento mibici-equipo01.
- **Making Predictions (Predicciones):** Ejecución en modo *batch* (por lotes) de manera diaria o semanal para abastecer los requerimientos operativos de la jornada siguiente.
- **Decisions (Decisiones):** Planificación de la flota de vehículos de rebalanceo dinámico, reubicación preventiva de bicicletas en horas pico y rediseño o expansión de cicloestaciones urbanas.
- **Impact Simulation (Simulación de Impacto):** Minimización de costos operativos por kilómetro recorrido en camionetas de rebalanceo y maximización de viajes completados con éxito por parte de los usuarios ciudadanos.
- **Monitoring (Monitoreo):** Seguimiento constante de métricas de desempeño de los modelos (RMSE, ROC-AUC, Silhouette Score) y detección temprana de deriva de datos (*data drift*).

Análisis Detallado de las Tres Preguntas

- **P1 (Regresión): ¿Cuántos viajes se iniciarán en una estación o zona en un periodo futuro?**
    1. *Formulación y Granularidad:* Predicción del número absoluto de viajes iniciados por estación en un horizonte temporal de 1 hora o 1 día (granularidad espacio-temporal por estación y bloque horario).
    2. *Relevancia Operativa:* Permite anticipar picos de demanda de transporte público en puntos neurálgicos de la ciudad, evitando cuellos de botella en la infraestructura.
    3. *Usuario y Decisión:* El **Operador del sistema MiBici**, quien utilizará la predicción para planear la distribución y el tamaño de la flota de bicicletas disponibles en cada cicloestación antes del inicio de la jornada operativa.
- **P2 (Clasificación): ¿Una estación estará en riesgo de quedarse sin bicicletas o sin anclajes disponibles en un periodo futuro?**
    1. *Formulación y Granularidad:* Predicción de una variable binaria (si hay riesgo crítico de desabastecimiento de bicicletas o saturación de anclajes, en caso contrario) a nivel de estación en la siguiente ventana de 1 a 3 horas.
    2. *Relevancia Operativa:* Previene la insatisfacción del usuario al llegar a una estación completamente vacía o sin espacio para retornar su bicicleta.
    3. *Usuario y Decisión:* El **Equipo de rebalanceo de bicicletas**, el cual desplegará camionetas de traslado de unidades de manera preventiva hacia las estaciones catalogadas en alto riesgo.
    4. *Aproximación del Riesgo (Proxy de Riesgo):* Dado que los datos abiertos no incluyen inventario en tiempo real, el riesgo se aproxima calculando la diferencia acumulada (flujo neto) entre salidas y llegadas de viajes por estación en la ventana de las próximas 3 horas, contrastada con la capacidad declarada en la nomenclatura (dpcapacity). Si el flujo neto futuro supera alpha × capacidad con alpha = 0.5 (la mitad de la capacidad), la estación se quedaría vacía o sin anclajes y la hora se etiqueta como riesgo (columna riesgo).
- **P3 (Clustering): ¿Qué grupos de estaciones comparten patrones de uso y dónde se ubican en la ciudad?**
    1. *Formulación y Granularidad:* Agrupamiento no supervisado de las estaciones de MiBici basándose en su perfil temporal de uso (proporción de viajes iniciados en hora pico matutina, vespertina, nocturna y fines de semana). Granularidad espacial a nivel estación con horizonte estacional/histórico.
    2. *Relevancia Operativa:* Revela la vocación urbana de cada zona de la ciudad (corredores financieros, zonas residenciales, áreas universitarias o distritos recreativos).
    3. *Usuario y Decisión:* El área de **Planeación urbana y expansión del sistema**, para justificar la apertura de nuevas cicloestaciones, rediseñar políticas tarifarias o proponer incentivos de uso cruzado.

2. Definición de los Datos, Justificación Temporal y Partición

- **Fuente de Datos:** Portal de Datos Abiertos de MiBici (archivos CSV mensuales de viajes y el archivo de nomenclatura vigente de estaciones, en https://www.mibici.net/es/datos-abiertos/
)
- **Rango de Fechas y Justificación Rigurosa del Periodo Post-Pandemia (2023–2026):**
  Aunque el sistema MiBici publica registros desde diciembre de 2014, para este proyecto se ha seleccionado estrictamente el periodo comprendido entre el 1 de mayo de 2023 y el 30 de septiembre de 2026 (41 meses). Esta decisión metodológica se fundamenta en los siguientes criterios técnicos:
  - **Mitigación de Rupturas Estructurales (COVID-19):** Los años 2020 a 2022 sufrieron alteraciones extremas y atípicas en los patrones de movilidad urbana debido a las restricciones sanitarias y el confinamiento. Entrenar modelos de Machine Learning con datos de ese periodo introduciría un sesgo severo que no refleja la dinámica actual de la ciudad.
  - **Consolidación del Nuevo Equilibrio de Movilidad:** A partir de 2023 se estabilizó un nuevo paradigma de movilidad híbrida (oficinas y universidades presenciales con rutinas post-pandemia consolidadas), garantizando que los patrones espacio temporales sean estables.
  - **Madurez de la Red de Cicloestaciones:** Tomar datos a partir de 2023 asegura que la red analizada cuente con una cobertura espacial madura y homogénea, evitando estaciones con trayectorias de datos incompletas en su etapa de apertura inicial.
  - **Suficiencia Estadística:** El periodo seleccionado aporta un volumen óptimo de **15,376,127 registros de viajes distribuidos en las 484 estaciones de la nomenclatura (473 con viajes en el periodo; entre 300 y 468 activas cada mes)**, robusto para entrenar algoritmos sin incurrir en costos computacionales excesivos derivados de procesar una década completa de datos heterogéneos.
- **Variables Originales y Construcción de Objetivos:**
  - *Variables Originales:* viaje_id, usuario_id, genero, anio_nacimiento, inicio_viaje, fin_viaje, origen_id, destino_id.
  - *Construcción P1:* Variable objetivo salidas (viajes con origen en la estación que inician en cada hora).$it + 1$
  - *Construcción P2:* Variable objetivo binaria riesgo derivada del balance de entradas/salidas frente a la capacidad (dpcapacity) de la estación.
  - *Construcción P3:* Vectores estandarizados de distribución horaria de viajes por estación.
- **Condiciones de Uso y Privacidad:** Los datos son de libre acceso bajo los términos de datos abiertos de MiBici. Para garantizar la protección de datos personales, **no se almacenan ni procesan variables identificables de los usuarios** (se omiten o

anonimizan campos de edad, género o identificadores de usuario, empleando exclusivamente agregaciones estadísticas anonimizadas).

- **Estrategia de Partición Cronológica:** Para evitar estrictamente la fuga de información (*data leakage*) y simular un entorno real de producción donde el modelo predice el futuro utilizando únicamente el pasado, los datos se dividieron en tres cortes temporales sucesivos:
    - *Entrenamiento (Train): 1 de mayo de 2023 – 31 de diciembre de 2024 (48.6% del volumen).*
    - *Validación (Val):* Enero 2025 – Junio 2025 (14.8% del volumen, utilizado para optimización e hiperparámetros).
    - *Prueba (Test): 1 de julio de 2025 – 30 de septiembre de 2026 (36.6% del volumen, reservado exclusivamente para la evaluación final no sesgada).*

3. Diseño del Pipeline de Machine Learning

- **Limpieza de Datos:** Estandarización de nombres de columnas al esquema canónico, conversión estricta de tipos (fechas a datetime, identificadores a enteros) y conservación de valores ausentes como nulos explícitos, sin filtrados adicionales de duración.
- **Feature Engineering y Agregaciones (features.py):** Agrupación espacio-temporal por estación y hora; cálculo de rezagos temporales (de 1 hora, 24 horas y 7 días previos), medias móviles rodantes y variables geográficas derivadas de la nomenclatura oficial; la rejilla estación×hora incluye las horas sin viajes con 0.
- **Entrenamiento y Evaluación:** Ajuste de modelos sobre el conjunto de entrenamiento, ajuste de hiperparámetros con el conjunto de validación (partición cronológica estricta, sin fuga de información hacia el futuro) y evaluación final sobre el conjunto de prueba, con todo registrado en MLflow Tracking. El código trae pruebas automatizadas (pytest) y trazabilidad de versiones (Wilson, 2022).

4. Modelos, Métricas y Justificación

- **Pregunta P1 (Regresión):**
    - *Baseline:* Regresión lineal con regularización Ridge sobre las features de la estación y la hora (run P1-baseline-ridge).
    - *Modelo Candidato:* RandomForestRegressor (run P1-candidato-rf).
    - *Métricas: test_rmse* y test_mae (más test_r2), seleccionadas porque el RMSE penaliza con mayor severidad los errores grandes de planeación y mantiene las unidades originales de conteo de viajes (fácil interpretabilidad operativa).
- **Pregunta P2 (Clasificación):**
    - *Baseline:* Clasificador por clase mayoritaria (DummyClassifier con estrategia most_frequent, run P2-baseline-dummy).
    - *Modelo Candidato:* LogisticRegression con balanceo de clases (runs P2-baseline-dummy y P2-candidato-logreg).

    - *Métrica:* test_roc_auc y test_f1_macro, ideales para evaluar el rendimiento general ante escenarios de clases desbalanceadas (altas tasas de operación normal frente a casos aislados de riesgo crítico donde los falsos negativos representan usuarios sin bicicleta).
- **Pregunta P3 (Clustering):**
    - *Baseline:* K-Means aleatorio simple (KMeans con inicialización init='random', run p3-baseline-k5).
    - *Modelo Candidato: K-Means++ con normalización previa de perfiles temporales de uso (runs p3-candidate-k6, k10 y k20).*
    - *Métrica:* silhouette_score para evaluar la cohesión intra-cluster y separación inter-cluster, complementado con el método del codo para definir el número óptimo de agrupamientos.K

5. Arquitectura del Sistema

El diagrama conceptual de la solución consta de las siguientes capas interconectadas:

1. **Capa de Fuentes Externas:** Portal de Datos Abiertos MiBici (descarga de CSVs remotos).
2. **Capa de Ingesta y Versionado:** Script automatizado (dataset.py) que descarga, normaliza, exporta a formato Parquet y genera un manifiesto con hashes SHA-256 versionado en Git.
3. **Capa de Almacenamiento Local:** Estructura de directorios estandarizada por Cookiecutter Data Science (data/raw/, data/processed/).
4. **Capa de Procesamiento y Características:** Módulo reutilizable de transformaciones puras (features.py).
5. **Capa de Modelado y Trazabilidad:** Scripts de entrenamiento integrados con **MLflow Tracking** (almacenando parámetros, métricas, artefactos y vinculados al commit de Git activo).

Justificación Teórica (según Huyen y Treveil et al.): Se selecciona Pandas y Apache Parquet debido a su eficiencia superior en compresión y velocidad de lectura para volúmenes medianos de datos tabulares; Cookiecutter Data Science (Drivendata, s.f.) para estandarizar la colaboración en equipo y mitigar la deuda técnica estructural; y MLflow para garantizar la auditabilidad, reproducibilidad y trazabilidad completa de los experimentos de Machine Learning.

6. Ejecución del Experimento Base en MLflow

- **Nombre del Experimento:** mibici-equipo01
- **Runs Ejecutados:** Seis runs, dos por pregunta: P1-baseline-ridge y P1-candidato-rf (regresión), P2-baseline-dummy y P2-candidato-logreg (clasificación), y p3-baseline-k5 y p3-candidate-k6, k10 y k20 (clustering).

- **Parámetros Registrados:** Ventanas de las particiones (train 2023-05-01 a 2024-12-31, val hasta 2025-06-30, test hasta 2026-09-30), versión de los datos (hashes SHA-256 del manifiesto y del Parquet), semilla aleatoria global (42) e hiperparámetros del modelo base.
- **Métricas Registradas:** Nombres formales con prefijo indicando el conjunto de evaluación (test_mae, test_rmse, test_roc_auc, test_f1_macro, test_silhouette_score).
- **Etiquetas (Tags):** equipo: 01, pregunta: P1|P2|P3, commit: [hash_del_commit].
- **Artefactos:** Gráficas de distribución de errores residuales, matrices de confusión y mapas de dispersión/agrupamiento de estaciones guardados en reports/figures/ y registrados como artefactos en MLflow Tracking.

7. Evidencia Visual y Estructura del Repositorio

- **Estructura CCDS y Base Reproducible:** El repositorio (`laloz60/TC5061-Proyecto-Equipo01`) tiene una arquitectura modular estándar (`data/`, `notebooks/`, `mibici/`, `references/`, `reports/figures/mlflow_evidencia/`).

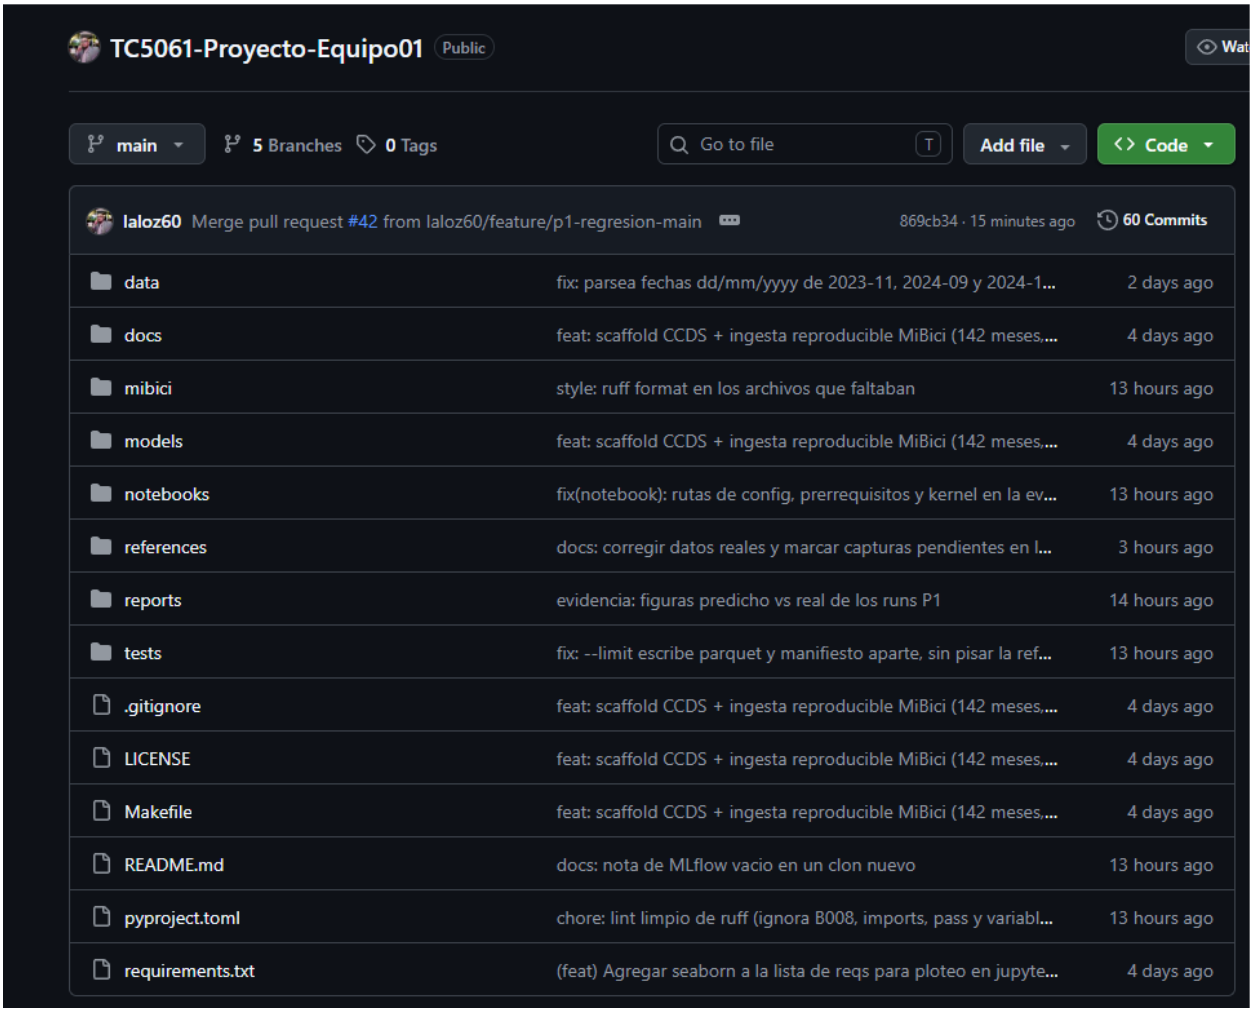


Imagen: estructura del repositorio TC5061-Proyecto-Equipo01 en GitHub (rama main) con las

carpetas data/, docs/, mibici/, models/, notebooks/, references/, reports/ y tests/, más los archivos de configuración raíz.

- **Flujo de Trabajo Git / GitHub:** Rama principal (`main`) protegida con requerimiento de Pull Request y revisión aprobada por un integrante (VoBo), siguiendo Conventional Commits.
- **Capturas de MLflow:**

Las siguientes capturas de MLflow evidencian el experimento base en el experimento mibici-equipo01 para cada pregunta (P1, P2 y P3): la lista de runs, el detalle de un run con parámetros, métricas y etiquetas, los artefactos registrados y la comparación de runs.

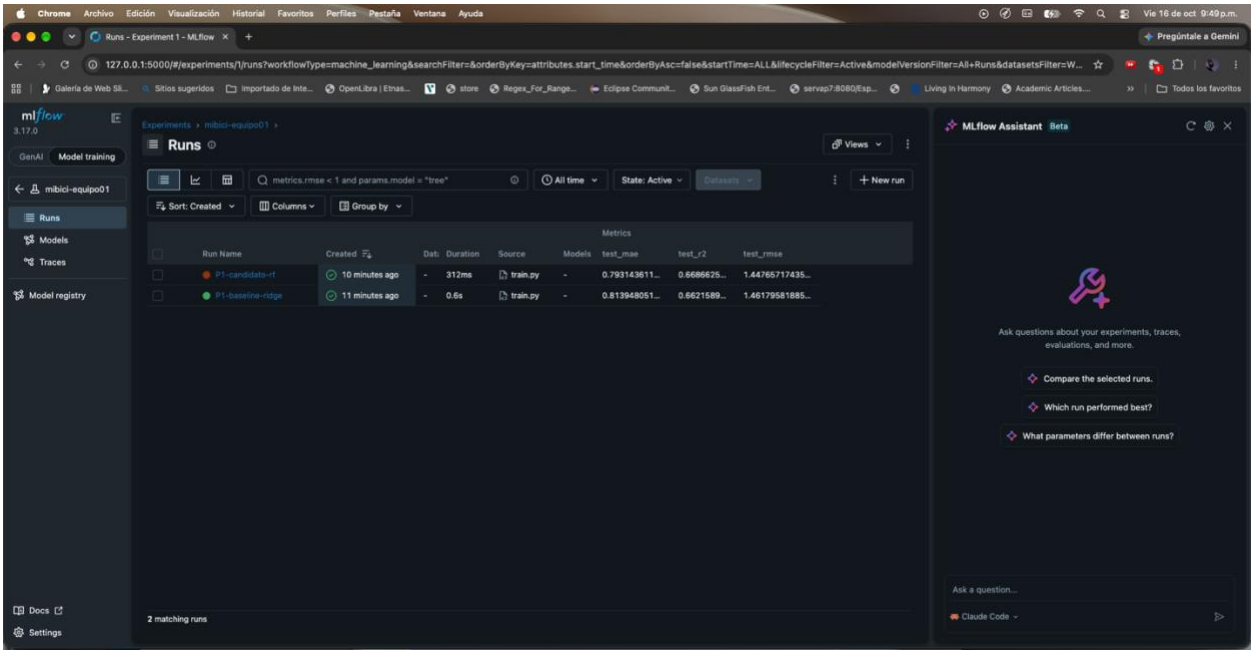


Imagen: lista de runs del experimento mibici-equipo01 con los dos entrenamientos de P1 (baseline-ridge y candidato-rf) y sus métricas.

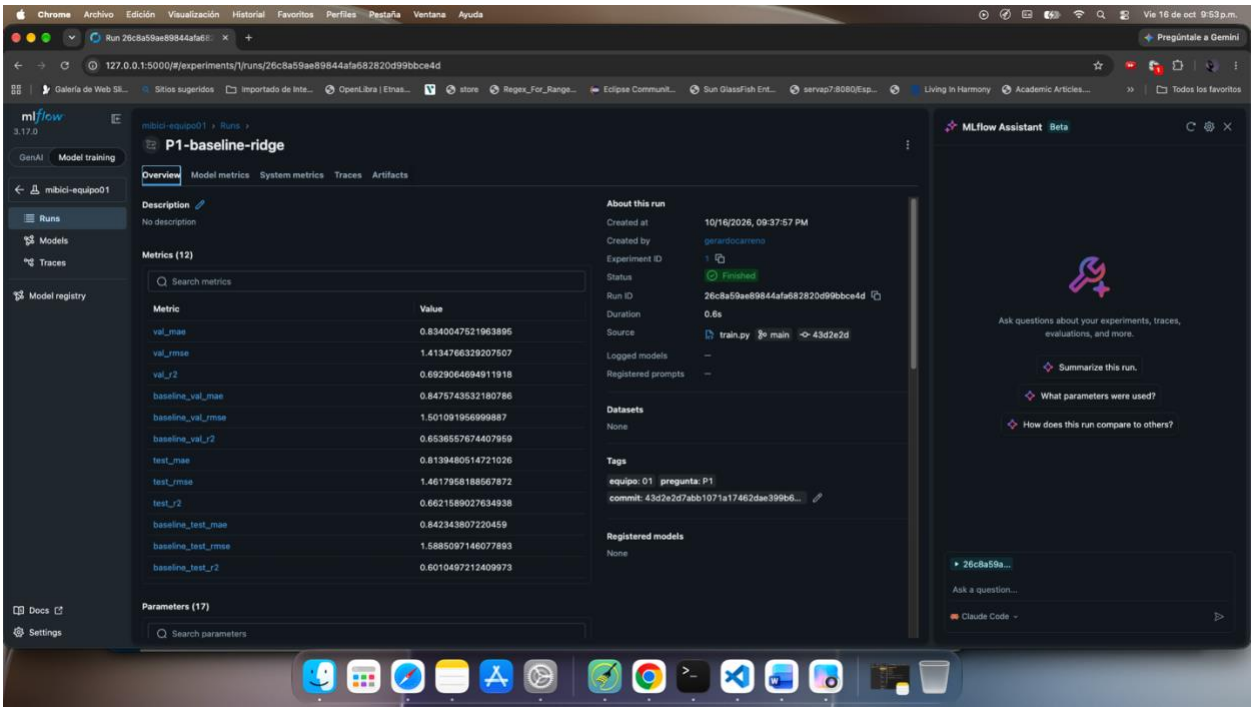


Imagen: detalle del run P1-baseline-ridge: estado, duración, métricas y etiquetas de tracking equipo=01, pregunta=P1 y commit.

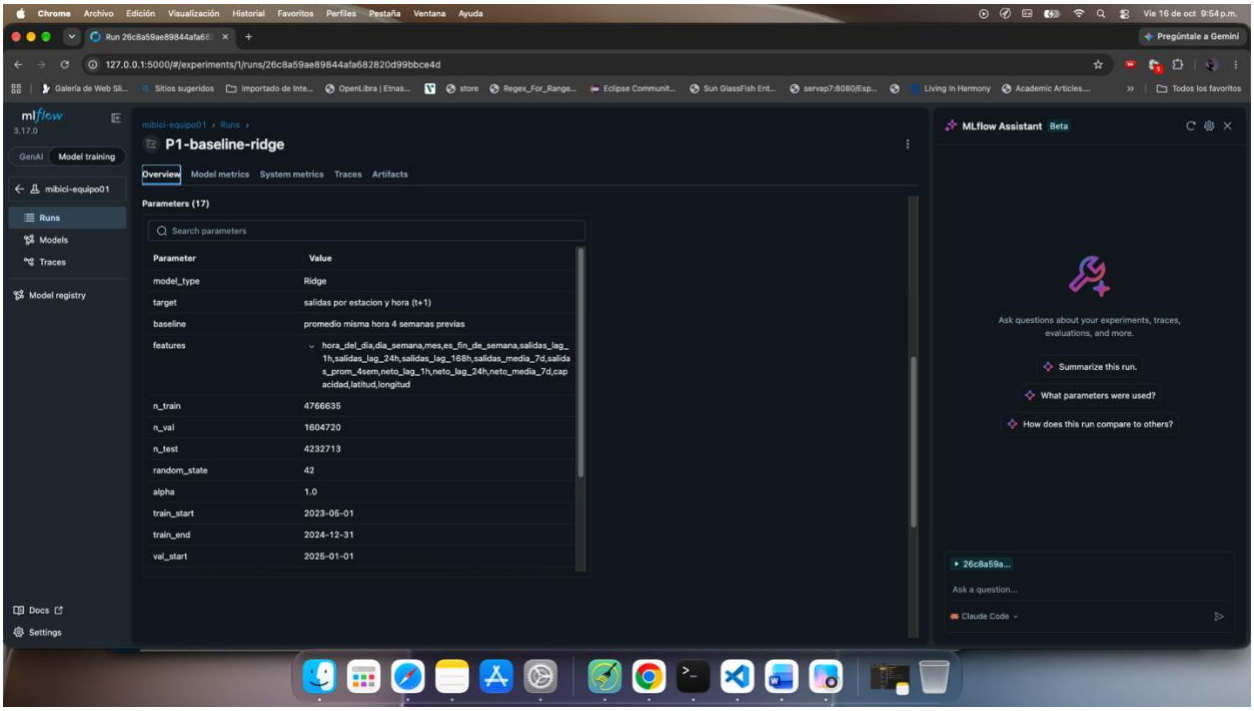


Imagen: parámetros del run P1-baseline-ridge: modelo, variable objetivo, baseline, features, tamaños de split, semilla e hiperparámetros (alpha, fechas del split temporal).

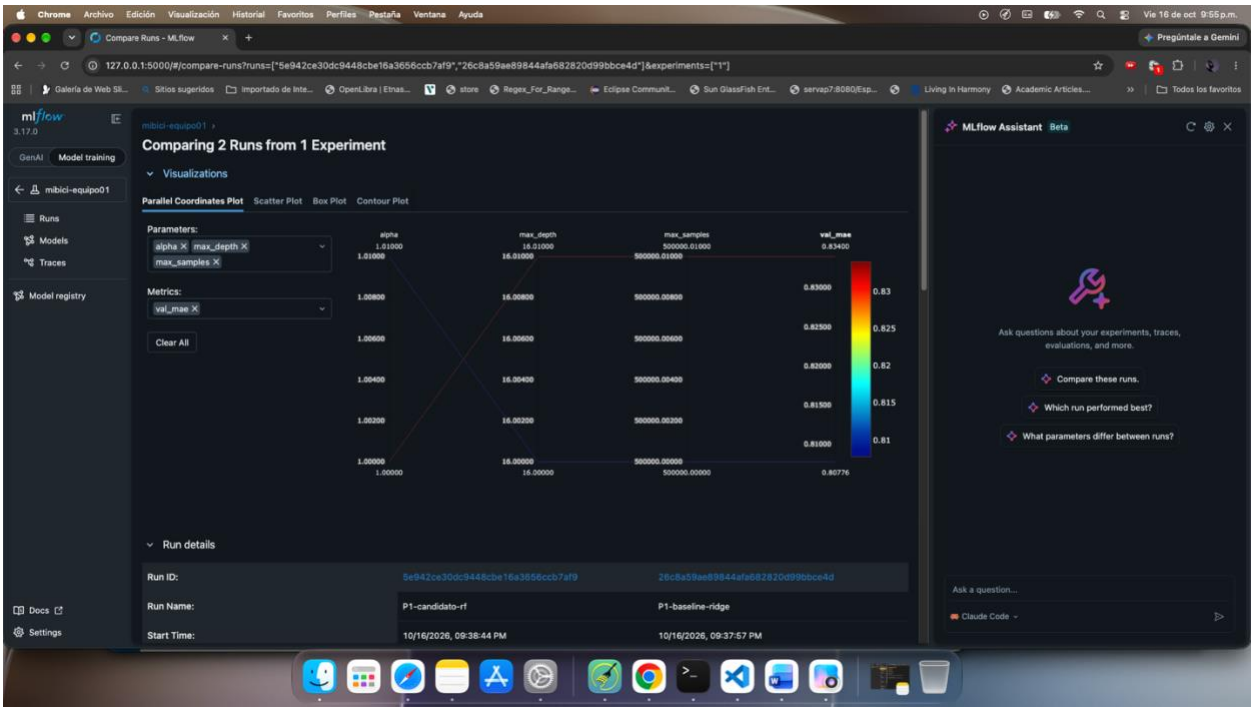


Imagen: comparación de P1-baseline-ridge contra P1-candidato-rf en coordenadas paralelas con sus hiperparámetros y la métrica val_mae.

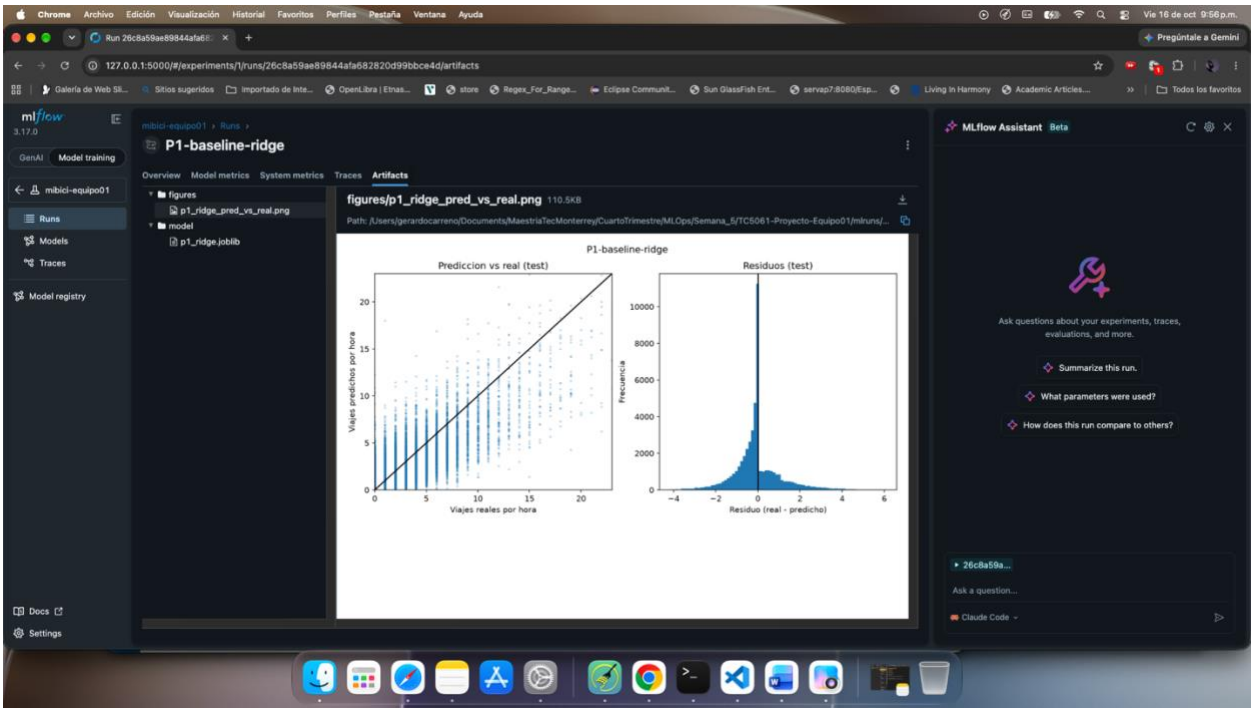


Imagen: artefactos del run P1-baseline-ridge: modelo serializado (p1_ridge.joblib) y gráfica de predicciones vs reales con histograma de residuos.

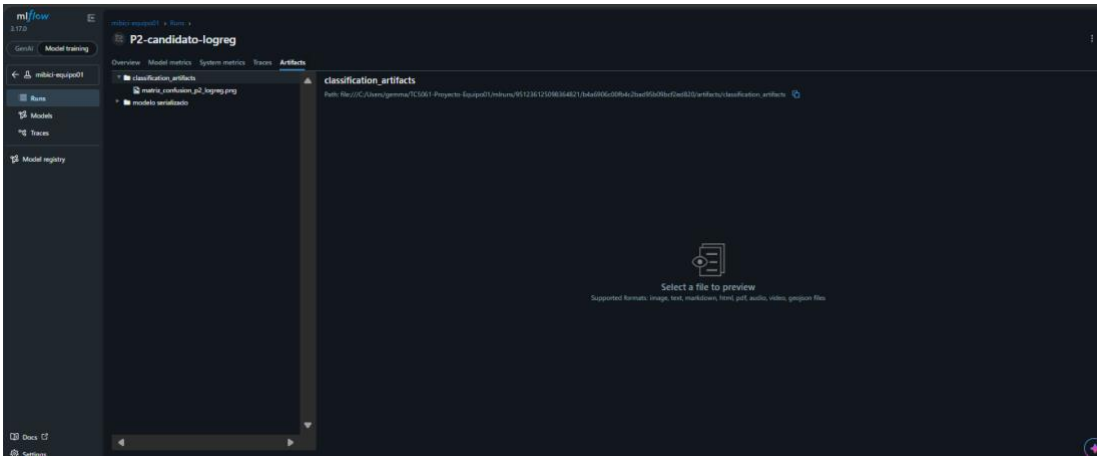


Imagen: artefactos del run P2-candidato-logreg: matriz de confusión y modelo serializado.

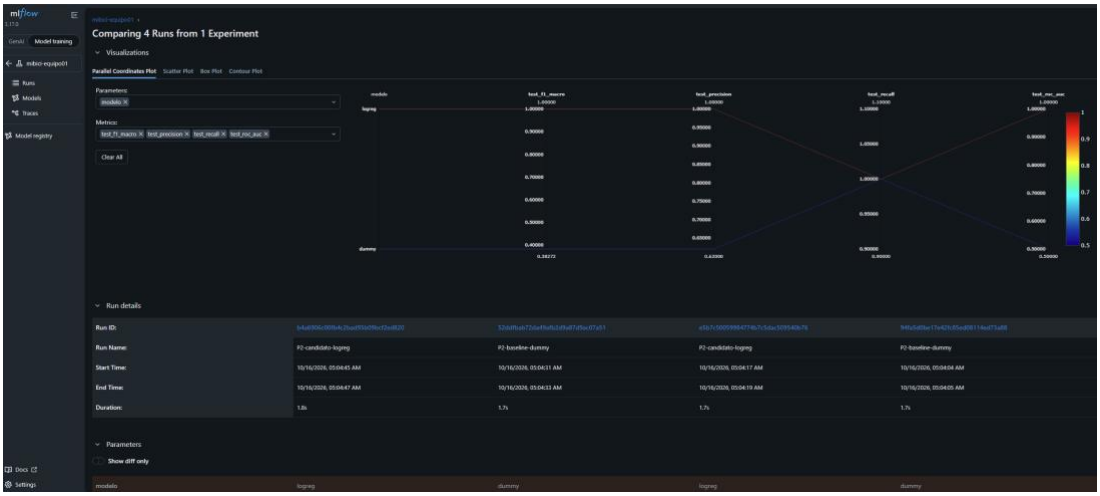


Imagen: comparación de los cuatro runs de P2 (dos dummy y dos logreg) en coordenadas paralelas con las métricas test_f1_macro, test_precision, test_recall y test_roc_auc.

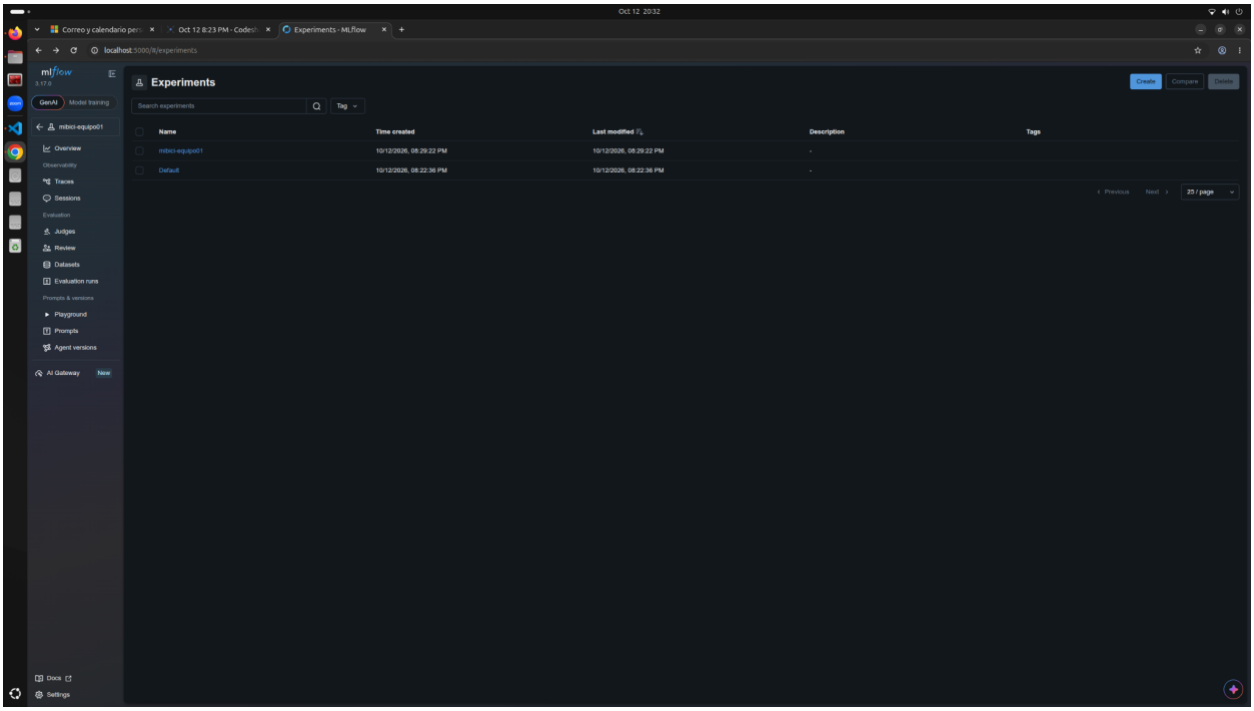


Imagen: experimento mibici-equipo01 en la interfaz de MLflow.

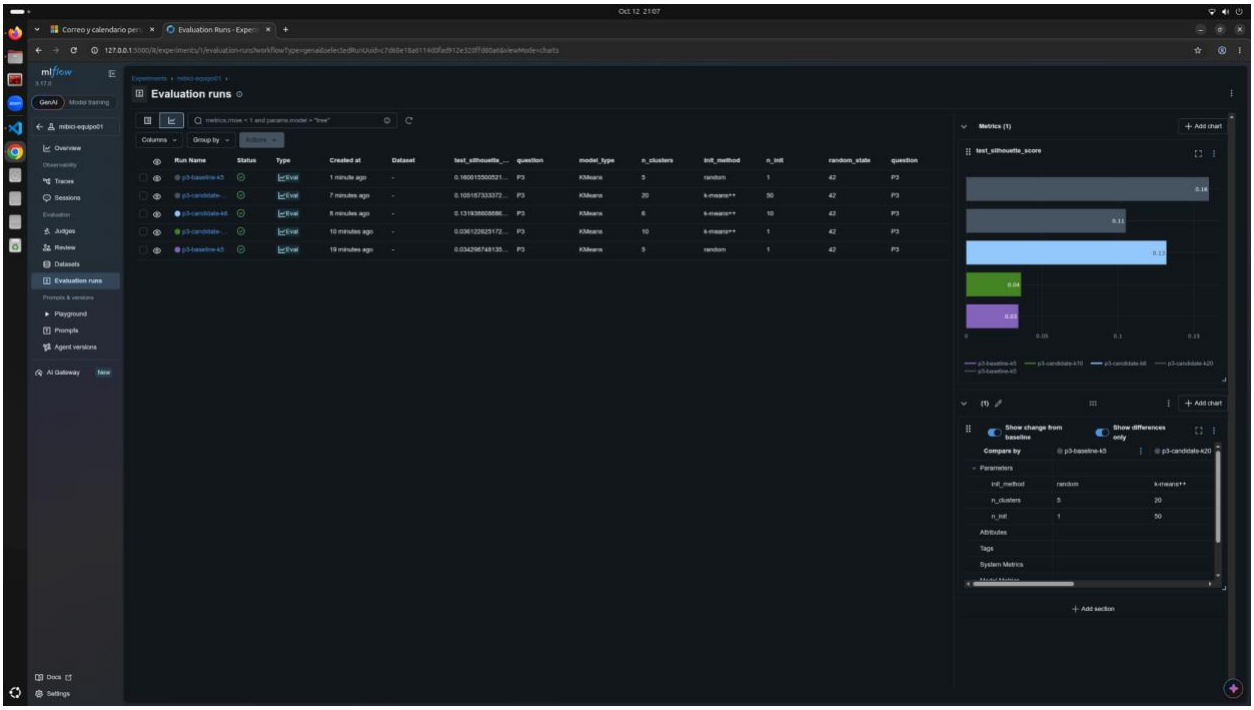


Imagen: comparación de runs de P3 (baseline y candidatos por k).

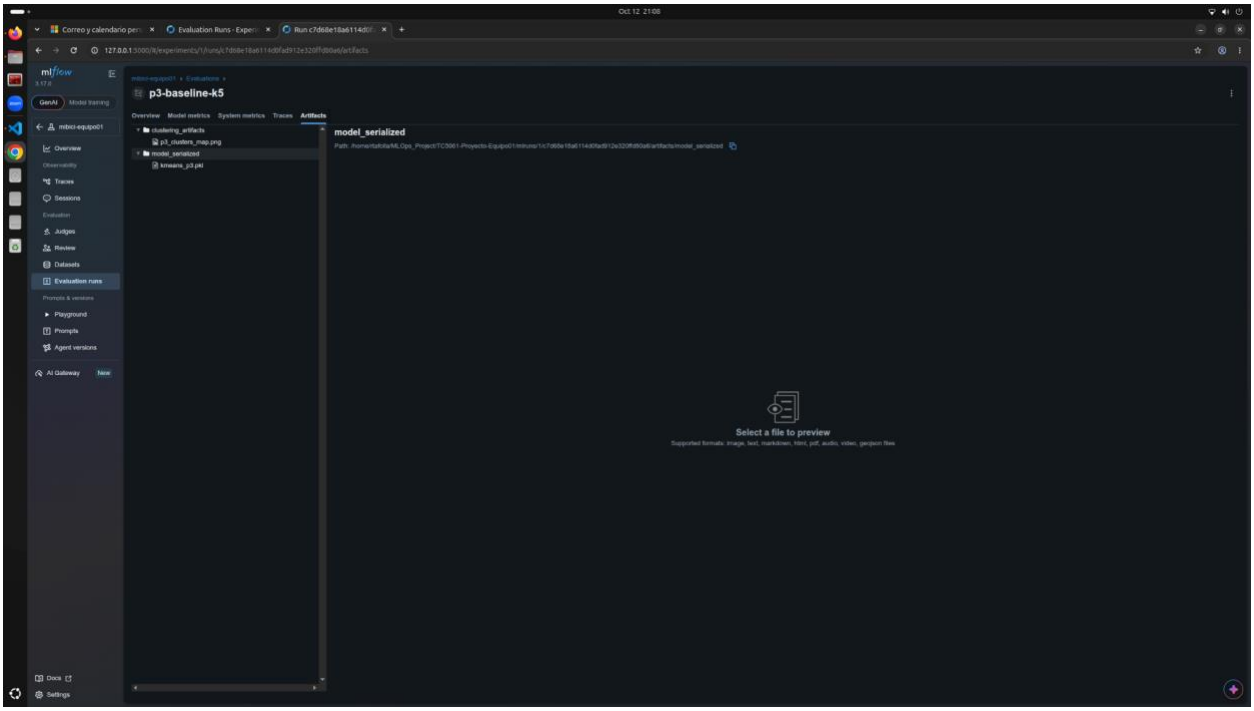


Imagen: detalle de un run de P3 con sus artefactos (modelo serializado y mapa de clústeres).

Referencias

Dorard, L. (2018, 9 de marzo). *From data to AI with the Machine Learning Canvas (Part I)*. Own Machine Learning (Medium). https://www.ownml.co/

Drivendata. (s.f.). Cookiecutter Data Science [Software]. GitHub. https://github.com/drivendata/cookiecutter-data-science

Huyen, C. (2022). *Designing machine learning systems: An iterative process for production-ready applications*. O'Reilly Media.

MiBici. (s.f.). *Datos abiertos* [Conjunto de datos]. Sistema de Bicicleta Pública del Área Metropolitana de Guadalajara. https://www.mibici.net/

MLflow. (s.f.). *MLflow Tracking* [Documentación]. MLflow. https://mlflow.org/

Treveil, M., Omont, N., Stenac, C., Lefevre, K., Phan, D., Zentici, J., Lavoillotte, A., Miyazaki, M., & Heidmann, L. (2020). *Introducing MLOps: How to scale machine learning in the enterprise*. O'Reilly Media.

Wilson, B. (2022). *Machine Learning Engineering in Action*. Manning Publications.